UNIVERSIDADE DA CORUÑA

Grado en Inteligencia Artificial – Fundamentos de Procesamiento de Lenguaje Natural

Curso 2025-2026

Práctica 2: Aprendizaje Auto-supervisado de Representaciones Semánticas Distribucionales Estáticas

Esta práctica consiste en implementar dos modelos de redes neuronales para generar word embeddings (representaciones vectoriales de palabras) a partir de corpus extensos. Estos modelos son fundamentales en la historia del PLN, ya que establecieron las bases para capturar relaciones semánticas entre palabras mediante vectores de manera efectiva[1], un principio que sigue vigente en los modelos de lenguaje modernos de alta complejidad.

CBOW (Continuous Bag of Words): Este modelo genera representaciones vectoriales mediante la predicción de una palabra objetivo basándose en su contexto circundante. Su proceso de entrenamiento emplea una ventana deslizante que recorre el texto palabra por palabra para definir, en cada posición, una palabra central como salida y un número determinado de palabras anteriores y posteriores como entrada. Por ejemplo, al configurar una ventana de cinco elementos, el sistema utiliza las dos palabras a la izquierda y las dos a la derecha para inferir el término central, excluyendo siempre la palabra objetivo del conjunto de datos de entrada.

Skip-gram: Modelo que genera representaciones vectoriales mediante la predicción del contexto circundante a partir de una única palabra objetivo. A diferencia del modelo previo, este enfoque utiliza una única palabra como entrada para predecir las palabras de su contexto circundante. El proceso de generación de muestras selecciona una palabra objetivo del texto y crea pares individuales con cada uno de los términos situados dentro de un rango predefinido. Por ejemplo, con un rango de dos palabras, la frase "el gato negro duerme" generaría para la palabra objetivo "gato" los pares ("gato", "el"), ("gato", "negro") y ("gato", "duerme"). De este modo, el modelo se entrena para calcular la probabilidad de que cada palabra de contexto aparezca habitualmente cerca de la palabra central proporcionada.

El modelo Skipgram requiere además de ciertas consideraciones para obtener representaciones significativas:

a. Muestreo negativo: Esta técnica evita que el modelo aprenda soluciones triviales al presentarlo no solo ante pares positivos (palabra objetivo y contexto real), sino también ante pares negativos formados por palabras aleatorias del vocabulario. Así, el modelo aprende a distinguir entre contextos auténticos y falsos. En la práctica se pide establecer el número de muestras negativa por cada positiva en 4.

b. Entrenamiento balanceado: Debido a que el muestreo negativo genera una gran disparidad entre la cantidad de ejemplos positivos y negativos, es habitual establecer pesos de clase durante el entrenamiento. Esto compensa el desbalance y obliga al modelo a otorgar la misma importancia a ambos tipos de muestras.

c. Submuestreo de palabras frecuentes: Términos muy comunes (como "el" o "de") aportan poco valor semántico. Para mitigar este problema, Mikolov et al. [1] proponen descartar cada palabra del texto

original con una probabilidad (por tanto, acotada en [0,1]) y basada en la fórmula $P(w) = 1 - \sqrt{(t / f(w))}$, donde f(w) es frecuencia relativa de la palabra en el corpus y t es un umbral configurable, típicamente 10^{-3}.

Para más detalles sobre los detalles de la práctica, tenéis también disponible el documento guia_pln.pdf.

Datos de entrenamiento: Se incluyen varios conjuntos de datos con los materiales de esta práctica, disponibles en la carpeta "datasets". Están en formato de texto plano y ya han sido preprocesados. En la memoria es suficiente con mostrar análisis con uno de ellos, pero durante la defensa se podrá probar cualquiera de ellos.

Arquitectura: Para ambos enfoques, es necesario implementar una arquitectura de red neuronal que integre los siguientes componentes (más detalles se incluyen en el documento guia_pln.pdf):

a. Una capa de entrada que acepte la(s) palabra(s) como entrada.

b. Una capa de Embeddings que asocia cada ID de palabra a un vector, y que se irá actualizando durante el entrenamiento. Los valores de esta capa serán los *word embeddings* de cada término.

c. Una o varias capas ocultas que procesen estas entradas y que dependerán de la arquitectura empleada.

4. Una capa de salida que genere las predicciones para cada modelo.

Funcionalidades Requeridas:

a. Entrenar los modelos utilizando un conjunto de entrenamiento y validar los modelos con un conjunto de desarrollo para ajuste de hiperparámetros.

b. Análisis cualitativo de los resultados. Para cada libro, se incluye con los materiales de la práctica una lista mínima de palabras que deberán ser visualizadas y comparadas, según lo indicado a continuación.

> a. Similitud Semántica: Para cada palabra objetivo, se debe calcular su afinidad con el resto del vocabulario utilizando la similitud del coseno sobre los vectores generados. Esta métrica permite determinar la proximidad semántica entre términos en el espacio vectorial. Deberán extraerse las 10 palabras más cercanas para cada objetivo y analizar en la memoria los resultados y relaciones más relevantes observados.
>
> b. Visualización mediante t-SNE: Para analizar gráficamente el agrupamiento semántico de las palabras, se empleará t-SNE (t-Distributed Stochastic Neighbor Embedding), una técnica de reducción de dimensionalidad que proyecta los vectores en un espacio bidimensional. La visualización resultante será un gráfico que muestre estos agrupamientos. Se proporciona un código de ejemplo junto con los materiales de esta práctica. Utilizando las funciones visualize_tsne_embeddings y visualize_all_tsne_embeddings, se deben generar dos comparativas críticas para las palabras objetivo: su disposición en el espacio antes y después del entrenamiento. Este contraste permitirá identificar visualmente los clústeres semánticos y las relaciones que la red ha logrado aprender.

Se valorará la inclusión de experimentos adicionales en la memoria, siempre que aporten valor, quedando a criterio del alumno. La motivación del experimento deberá estar correctamente justificada.

Por último, se valorará la inclusión y análisis de resultados obtenidos con el dataset text8, que corresponde a los primeros 100MB de la Wikipedia en inglés. Por tratarse de un conjunto de datos de mayor tamaño, el entrenamiento puede requerir varias horas; bastará con ejecutar una única época y entrenar solo el primer modelo propuesto (el basado en predicción de palabras). También se permite reducir el tamaño del dataset.

Entrega

Incluir un manual breve que detalle cómo ejecutar el código para entrenar y evaluar los modelos, un análisis de los resultados obtenidos, y una discusión sobre las diferencias observadas entre las dos implementaciones y sus ventajas e inconvenientes. La discusión no debe exceder las 5 páginas, pero se pueden usar páginas adicionales para incluir imágenes de gráficas y visualizaciones, etc.

La práctica se realizará en grupos de tres personas, respetando los formados al inicio de la asignatura.

La práctica deberá subirse al campus virtual, en el apartado habilitado para ello, como muy tarde el 10 de abril a las 23:59 horas. Únicamente un miembro del grupo debe subir la práctica.

La defensa (obligatoria) tendrá lugar durante las semanas siguientes de la práctica. Los estudiantes que no acudan a dicha defensa suspenderán la práctica con una nota de 0 puntos.

Bibliografía

[1] Mikolov, T., Sutskever, I., Chen, K., Corrado, G. S., & Dean, J. (2013). Distributed representations of words and phrases and their compositionality. Advances in neural information processing systems, 26.