

# **Visión por Computador Avanzada**

Segmentación de imágenes OCT

Noel Pan Brea  
Adrián Tinaquero Vizoso

17 de mayo de 2026

# Índice

|                                          |           |
|------------------------------------------|-----------|
| <b>1. Introducción</b>                   | <b>2</b>  |
| <b>2. Modelo Baseline</b>                | <b>2</b>  |
| <b>3. Mejoras</b>                        | <b>3</b>  |
| 3.1. Pesos . . . . .                     | 3         |
| 3.2. Focal Loss . . . . .                | 3         |
| 3.3. Augmentation . . . . .              | 3         |
| <b>4. Resultados experimentales</b>      | <b>4</b>  |
| 4.1. Baseline . . . . .                  | 4         |
| 4.2. Pesos añadidos . . . . .            | 6         |
| 4.3. Focal Loss . . . . .                | 7         |
| 4.4. Focal Loss y Augmentation . . . . . | 9         |
| 4.5. Comparativas de modelos . . . . .   | 11        |
| <b>5. Conclusiones</b>                   | <b>11</b> |

# 1. Introducción

El reconocimiento automático de estructuras anatómicas y lesiones en imágenes de tomografía de coherencia óptica (OCT) mediante técnicas de aprendizaje profundo es de gran interés en el ámbito de la Inteligencia Artificial, ya que puede aplicarse en sectores como la oftalmología clínica (incluyéndolo en el diagnóstico temprano de enfermedades como la degeneración macular asociada a la edad o el glaucoma) o la investigación biomédica, facilitando el trabajo de los especialistas.

En esta práctica se trabaja con un conjunto de imágenes obtenidas de escáneres OCT y su objetivo es el desarrollo de un modelo de segmentación capaz de identificar automáticamente las regiones oculares que contienen fluido patológico.

# 2. Modelo Baseline

Para el modelo baseline se utilizó una arquitectura sencilla basada en U-Net, ya que este tipo de redes funciona bastante bien en tareas de segmentación de imágenes médicas.

El modelo está dividido en dos partes principales: encoder y decoder. En la parte encoder la red va extrayendo características de la imagen mediante capas convolucionales y reduciendo el tamaño de la imagen usando max pooling. A medida que avanza la red, aumenta el número de canales de características (64, 128, 256 y 512).

Cada bloque convolucional está formado por dos convoluciones seguidas de una función de activación ReLU.

En la parte decoder se recupera poco a poco la resolución original de la imagen utilizando operaciones de upsampling. Además, se añaden conexiones entre encoder y decoder mediante concatenaciones para conservar información importante de las primeras capas.

Finalmente, se utiliza una convolución 1x1 para obtener la máscara final de segmentación con el número de clases deseado. Además, añadimos como transformación básica un escalado a 208 x 312 para agilizar el proceso de entrenamiento, se comprobó que el impacto en los resultados era bajo.

Este modelo se utilizó como punto de partida para después probar distintas mejoras como el uso de pesos en la función de pérdida, Focal Loss y técnicas de data augmentation. Las cuales, serán detalladas a continuación.

## 3. Mejoras

### 3.1. Pesos

Uno de los principales problemas del conjunto de datos es lo des balanceadas que están sus clases lo que provoca que el modelo tarde mucho en poder separar correctamente los patrones debido al peso que ejercen las instancias negativas. Como primera solución decidimos aplicar unos pesos en la función de pérdida equivalentes al ratio: N/P (Negativos/Positivos), para ello se empleó una función en el módulo train llamada `compute_pos_weight` que calcula dichos valores. Esta mejora aumentó moderadamente el IOU y el Dice pero su mayor contribución fue el gran aumento de la velocidad de convergencia

*Baseline: epoch 127*  $\longrightarrow$  *Mejora: epoch 85*

### 3.2. Focal Loss

Los dos mayores problemas de la mejora anterior son la necesidad de tener la frecuencia del conjunto de entrenamiento y la poca capacidad que presenta para segmentar los casos complejos como los píxeles entre los quistes, con el objetivo de tratar de arreglarlo, implementamos Focal loss Alpha: 0.75, Gamma: 2 cuyo objetivo es ponderar al alza las muestras difíciles y a la baja las más sencillas. Esta mejora solucionó en gran medida la cantidad de falsos positivos entre los quistes pero aumentó los falsos negativos en los quistes más grandes. Además mejoró ligeramente el IOU y el Dice.

### 3.3. Augmentation

El mayor problema de la anterior mejora es la cantidad de falsos negativos que tienen los quistes grandes. Para solucionarlo agregamos augmentation a nuestro conjunto de datos, este consistió en aplicar un `RandomFlip` y un `CenterCrop` a las imágenes y a sus máscaras. La reducción del ratio Negativos/Positivos gracias al `CenterCrop` y la eliminación de sesgos gracias a la inversión nos permitieron acelerar todavía más el entrenamiento, aumentar el gamma y disminuir el alpha (3, 0.25) de Focal loss y obtener una mejor segmentación. Esta mejora aumento muy ligeramente el IOU y el Dice pero mejoró mucho la estabilidad del modelo, el overfitting y la cantidad de falsos negativos en las predicciones

## 4. Resultados experimentales

### 4.1. Baseline

Cuadro 1: Rendimiento de diferentes valores de threshold en el modelo Baseline

| Threshold | Recall | Prec. | IOU    | Dice  |
|-----------|--------|-------|--------|-------|
| 0.1       | 0.864  | 0.821 | 0.756, | 0.841 |
| 0.2*      | 0.825  | 0.862 | 0.758, | 0.842 |
| 0.3       | 0.793  | 0.888 | 0.748, | 0.834 |
| 0.4       | 0.768  | 0.909 | 0.737, | 0.823 |

\* = Mejor configuración






Figura 1: Matriz de confusión del modelo baseline




(a) Sin escala logarítmica



(b) Con escala logarítmica

Figura 2: Función de pérdida del modelo baseline



(a) Ejemplo 1

(b) Ejemplo 2

Figura 3: Ejemplos de segmentación con baseline

## 4.2. Pesos añadidos

Cuadro 2: Rendimiento de diferentes valores de threshold en el modelo con pesos

| Threshold | Recall | Prec. | IOU    | Dice  |
|-----------|--------|-------|--------|-------|
| 0.6       | 0.981  | 0.715 | 0.703, | 0.794 |
| 0.7       | 0.978  | 0.729 | 0.717, | 0.807 |
| 0.8       | 0.973  | 0.749 | 0.737, | 0.825 |
| 0.95*     | 0.923  | 0.823 | 0.787, | 0.866 |

\* = Mejor configuración






Figura 4: Matriz de confusión del modelo con pesos añadidos



(a) Sin escala logarítmica

(b) Con escala logarítmica

Figura 5: Función de pérdida del modelo con pesos añadidos



(a) Ejemplo 1

(b) Ejemplo 2

Figura 6: Ejemplos de segmentación del modelo con pesos añadidos

### 4.3. Focal Loss

Cuadro 3: Rendimiento de diferentes valores de threshold en el modelo con Focal Loss

| Threshold | Recall | Prec. | IOU    | Dice  |
|-----------|--------|-------|--------|-------|
| 0.1       | 0.954  | 0.655 | 0.635, | 0.725 |
| 0.2       | 0.951  | 0.721 | 0.704, | 0.794 |
| 0.3       | 0.94   | 0.77  | 0.748, | 0.834 |
| 0.5*      | 0.886  | 0.864 | 0.798, | 0.875 |

\* = Mejor configuración








Figura 7: Matriz de confusión del modelo con focal loss




(a) Sin escala logarítmica



(b) Con escala logarítmica

Figura 8: Función de pérdida del modelo con focal loss



(a) Ejemplo 1

(b) Ejemplo 2

Figura 9: Ejemplos de segmentación del modelo con focal loss

#### 4.4. Focal Loss y Augmentation

Cuadro 4: Rendimiento de diferentes valores de threshold en el modelo con Focal Loss y augmentation

| Threshold | Recall | Prec. | IOU    | Dice  |
|-----------|--------|-------|--------|-------|
| 0.2       | 0.956  | 0.737 | 0.72,  | 0.81  |
| 0.3       | 0.919  | 0.826 | 0.787, | 0.866 |
| 0.35*     | 0.889  | 0.865 | 0.801, | 0.877 |
| 0.4       | 0.851  | 0.9   | 0.797, | 0.874 |

\* = Mejor configuración






Figura 10: Matriz de confusión del modelo con focal loss y augmentation




(a) Sin escala logarítmica



(b) En escala logarítmica

Figura 11: Función de pérdida del modelo con focal loss y augmentation



(a) Ejemplo 1

(b) Ejemplo 2

Figura 12: Ejemplos de segmentación del modelo con focal loss y augmentation

## 4.5. Comparativas de modelos

Cuadro 5: Comparativa de los diferentes modelos probados

| Modelo         | Recall | Prec. | IOU    | Dice  |
|----------------|--------|-------|--------|-------|
| Baseline       | 0.825  | 0.862 | 0.758, | 0.842 |
| Weighted       | 0.923  | 0.823 | 0.787, | 0.866 |
| Focal Loss     | 0.886  | 0.864 | 0.798, | 0.875 |
| Focal Loss Aug | 0.889  | 0.865 | 0.801, | 0.877 |

\* = Mejor configuración

## 5. Conclusiones

En este trabajo se ha desarrollado un sistema de segmentación automática de fluido patológico en imágenes OCT basado en una arquitectura U-Net, evaluando de forma progresiva distintas mejoras sobre un modelo baseline.

Los resultados obtenidos muestran que el modelo baseline ya alcanza un rendimiento razonable (Dice: 0.842, IOU: 0.758), lo que confirma la idoneidad de la arquitectura U-Net para este tipo de tarea. Sin embargo, el fuerte desequilibrio entre píxeles de fondo y píxeles de fluido limita tanto la velo-

cidad de convergencia como la calidad de la segmentación en los casos más difíciles.

La incorporación de pesos en la función de pérdida supuso la mejora más notable en términos de velocidad de convergencia, reduciendo la época de convergencia de 127 a 85, aunque su impacto en las métricas finales fue moderado. La sustitución por Focal Loss permitió mejorar la segmentación de los casos más complejos, reduciendo los falsos positivos entre quistes y obteniendo la mejor precisión de todos los modelos (0.864), a costa de un ligero aumento de los falsos negativos en quistes grandes. Finalmente, la adición de técnicas de augmentation contribuyó a estabilizar el entrenamiento, reducir el overfitting y corregir parcialmente dicho aumento de falsos negativos, logrando el mejor IOU (0.801) y Dice (0.877) globales.

Como líneas de trabajo futuro, sería interesante explorar arquitecturas más profundas como U-Net++, el uso de Dice Loss combinada con Focal Loss, o técnicas de augmentation más específicas para imágenes OCT como la simulación de ruido speckle.

En general, se puede ver que el modelo baseline ya consigue resultados bastante aceptables, pero todavía tiene margen de mejora, sobre todo por el desbalance de clases y la dificultad de segmentar correctamente los quistes más pequeños y los bordes.

En la tabla comparativa final, se puede observar que la diferencia del mejor modelo con el peor tampoco es enorme. Esto indica que el problema ya estaba bastante bien resuelto desde el baseline, pero las mejoras ayudaron a afinar el comportamiento del modelo.